ネットワークログメッセージの出力元関数の自動特定手法の提案

小林 諭[1], Gaspard Damoiseau-Malraux[2], 福田 健介[3]
[1]岡山大学, [2]ソルボンヌ大学, [3]国立情報学研究所

IA研究会 2025年3月3日

背景

- ネットワークトラブルシューティングにおけるログの調査
  - ログメッセージの記述のみでは何が起きたのか把握困難
  - OSSの場合、ソースコードの調査が必要
- ログメッセージとソースコードの対応付け
  - ログメッセージを出力した元のログ関数を特定する
  - 複数の既存技術の前提として活用される
  - システムの振る舞いを把握する上で有用

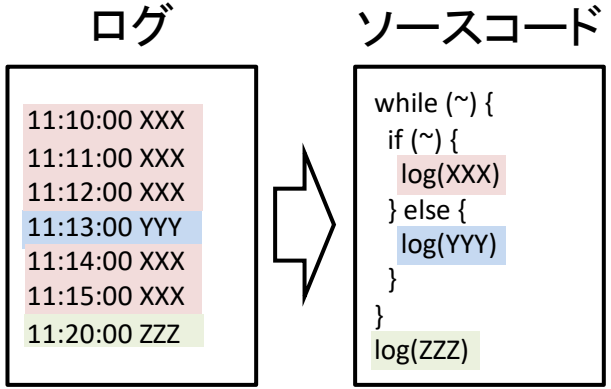

ログ出力元関数を特定する難しさ

- ログ出力元関数にはログのフォーマットが含まれるので、特定に活用したい
  - 一般的な単語が多い場合、単純な単語検索では候補が多すぎて非効率
  - 単語間にフォーマット指定子がある場合、検索対象に含めることが難しい

➢ログメッセージからログ出力元関数を自動特定したい

```
zlog_err("Instance %i out of range (0..%u)",
         instance, (unsigned short)-1);
```

既存のアプローチとその課題

- ソースコードから抽出したログ出力元関数を正規表現パターンに自動変換し、入力のログメッセージと照合する [7]
- 課題: ログメッセージごとにすべての正規表現の候補パターンと照合するため、大きなプロジェクトだと処理時間が大きい

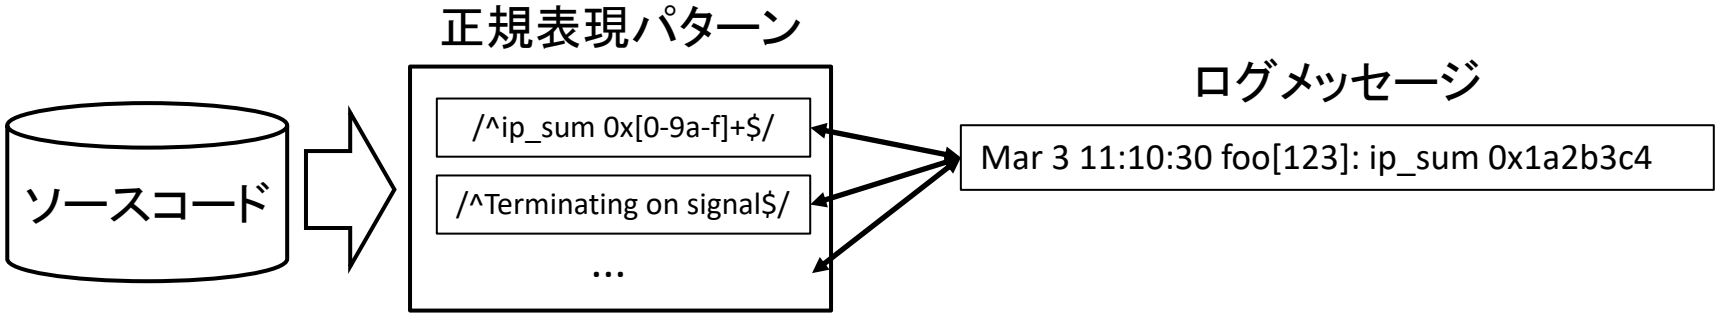

[7] W. Xu, et al. “Detecting large-scale system problems by mining console logs,” Proceedings of SOSP ’09, pp.117–132, 2009.

研究の目的

- ログメッセージを入力として対応するソースコード部分(ログ出力元関数)を自動特定するシステムの設計
  - ログメッセージと出力フォーマットの照合を高速に行うアプローチとして、正規表現によるマッチングとメッセージの単語分割下でのマッチングを組み合わせた新しい手法を提案
- 上記設計に基づく自動特定システムSCOLMを用いた評価
  - オープンソースルータFRRoutingを用いた処理時間の評価

既存研究

- 主に前処理としてログとソースコードの対応付けを実施

1. ログメッセージの分類のための出力フォーマット抽出[7,8,9]
   - ログメッセージのみからの推定より信頼性が高い
2. ログイベントの動作フロー上マッピング[11,13]
   - プログラムのソースコード上の振る舞いをログから可視化可能

➢いずれも正規表現による手法[7]を利用、高速な対応付けについては議論していない

[7] W. Xu, et al. “Detecting large-scale system problems by mining console logs,” SOSP ’09, pp.117-132, 2009.
[8] D. Schipper, et al. “Tracing back log data to its log statement: from research to practice,” MSR’19, pp.545-549, 2019.
[9] A. Pecchia, et al. “Industry practices and event logging: assessment of a critical software development process,” ICSE’15, pp.169–178, 2015.
[11] D. Yuan, et al. “SherLog : Error Diagnosis by Connecting Clues from Run-time Logs,” SIGARCH Comput. Archit. News, vol.38, pp.143-154, 2010.
[13] Q. Fu, et al. “Execution anomaly detection in distributed systems through unstructured log analysis,” ICDM’09, pp.149–158, 2009.

既存のログ照合技術

- WSPT (Word Segmented Prefix Tree) [17]
  - 単語かワイルドカードをノードとして持つプレフィックス木
  - 1つのワイルドカードには1つの単語のみが入る前提(=セパレータを含まない)
    - これを満たす単語分割テンプレート(WS-template)の集合から構築可能
  - ログメッセージのテンプレート分類を正規表現の1/10以下の時間で処理可能 [17]

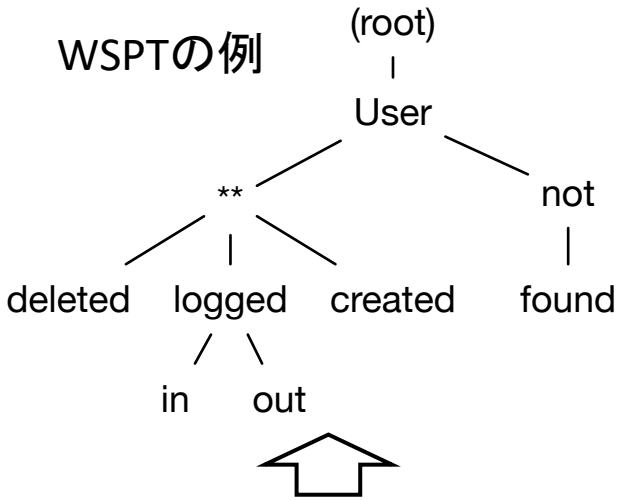

[17] S. Kobayashi, et al. “amulog: A general log analysis framework for comparison and combination of diverse template generation methods,” International Journal of Network Management, vol.32, no.4, p.e2195, 2022.

WSPTの問題点

- ソースコードから抽出した出力フォーマットはそのままでは単語分割テンプレート(WS-template)として利用不可
  - フォーマット指定子には複数の単語が埋め込まれうる
  - ➢「1つのワイルドカードに1つの単語のみが入る」前提を満たさない

正規表現の場合
フォーマット指定子は
複数単語とマッチしうる

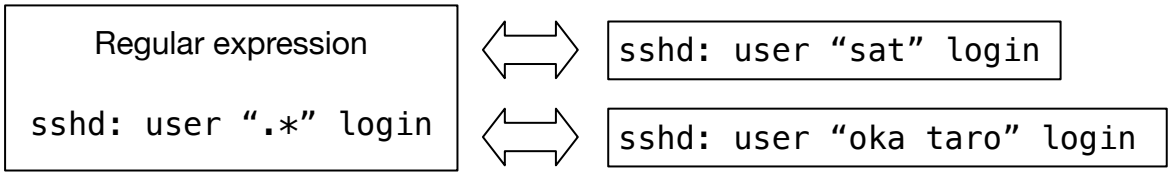

WSPTの場合
ワイルドカードは単一
単語とのみマッチする

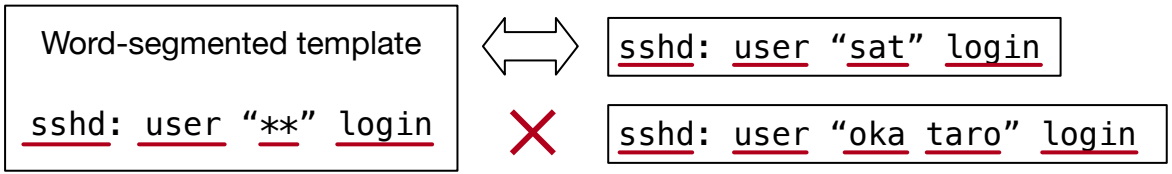

提案手法のアプローチ

- 正規表現とWSPTの併用
  - 実ログメッセージと正規表現パターンを対応づけ
    - ➢単語数が確定、WS-templateを生成可能
- WSPT -> 正規表現の順で照合
  - WSPTで発見 -> WS-templateに対応する正規表現のみ照合
  - WSPTで未発見 -> すべての正規表現を照合
  - ➢照合すべき正規表現をWSPTで絞り込み、処理を効率化

正規表現手法と同等の信頼性で、WSPTに準ずる処理速度を実現

Method	Processing time	External template	False positives
Regular expression	Large	Available	Small
WSPT	Small	Not available	Large
Proposed method	Small	Available	Small

提案手法の流れ

事前にソースコードから
正規表現パターン生成

WSPTには単純なテンプレートのみ事前追加
(高速化のための工夫)

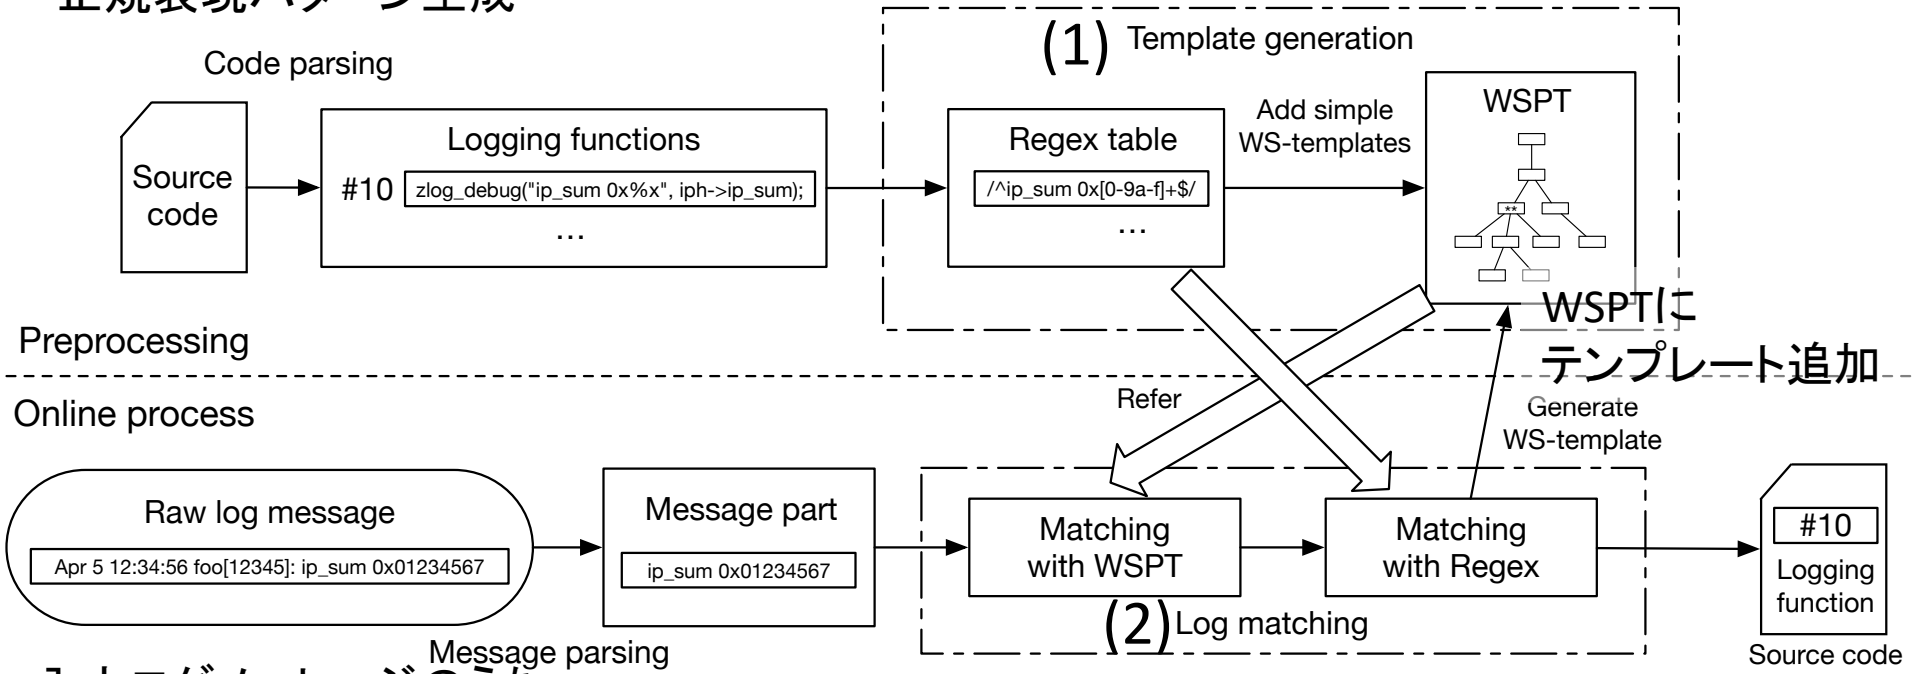

入力ログメッセージのうち
ヘッダを除くメッセージ部のみ利用

WSPTと正規表現を併用する
ログメッセージの照合

(1) テンプレート生成の手順

1. ソースコードからログ関数を抽出
2. フォーマット指定子を正規表現パターンに置き換え
3. フォーマット指定子につき1単語の単純なWS-templateを生成し、WSPTに追加

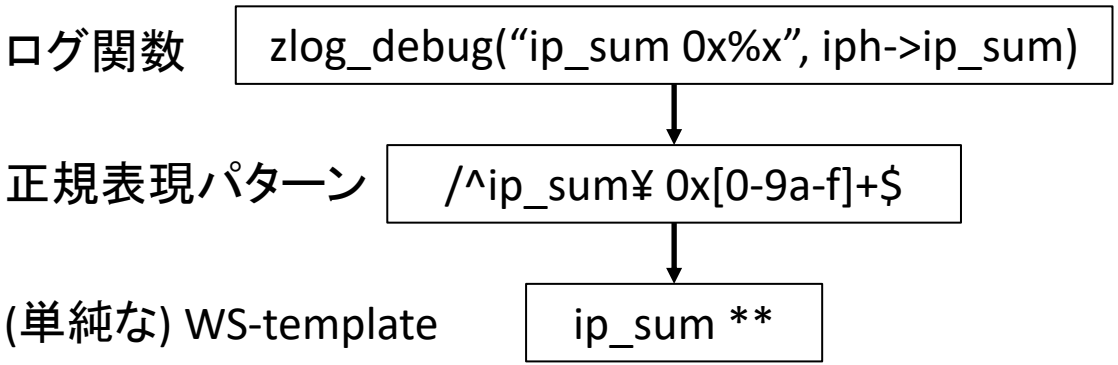

(2) ログマッチングの手順

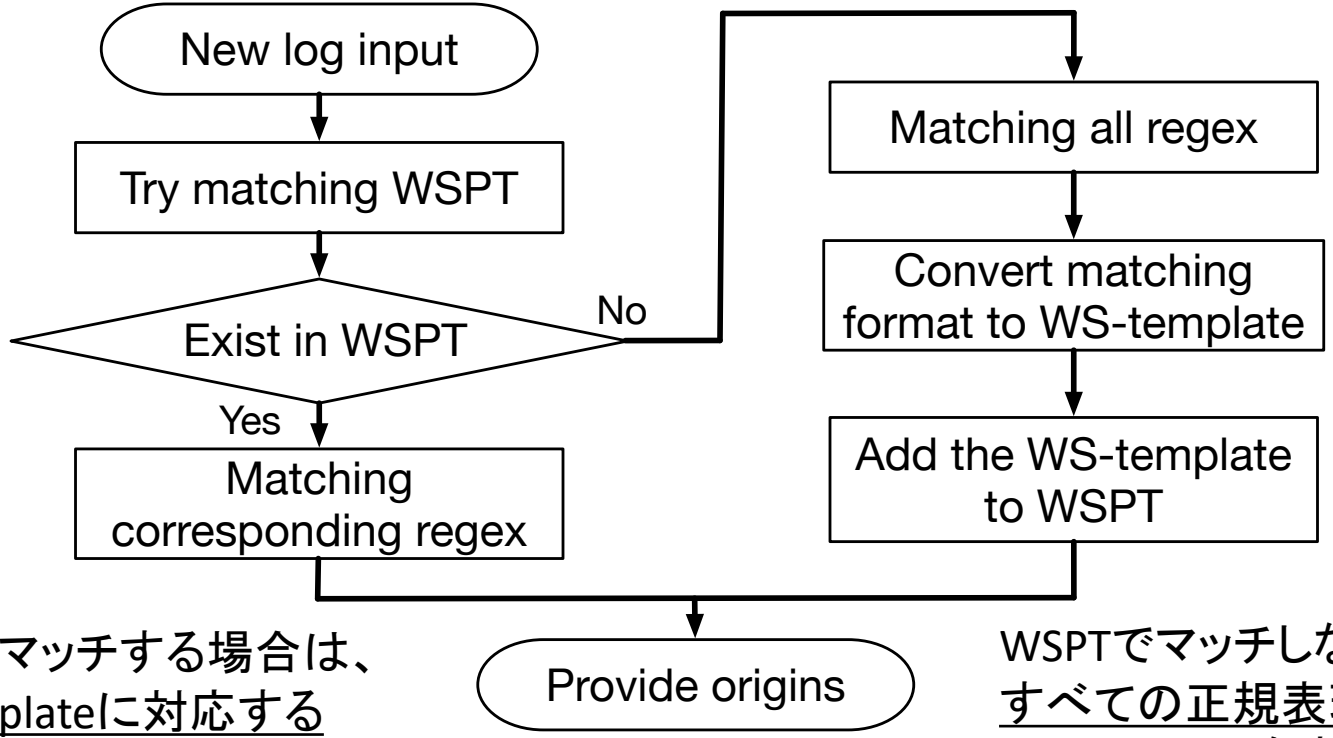

WSPTでマッチする場合は、
WS-templateに対応する
正規表現のみを照合

WSPTでマッチしない場合は、
すべての正規表現を照合、
WS-templateを生成・追加

実装

- SCOLM (Source Code Origins of Log Messages)
  - Python 3.10向けに実装
  - ソースコード分析部にはCtags[19]を利用
  - WSPTは、amulog[17, 20]をベースに実装
  - ログメッセージの単語分割にはlog2seq[17, 21]を利用
  - オープンソース公開を計画中

[17] S. Kobayashi, et al. “amulog: A general log analysis framework for comparison and combination of diverse template generation methods,” International Journal of Network Management, vol.32, no.4, p.e2195, 2022.
[19] Universal Ctags Team, “Universal ctags,” https://ctags.io/, 2021.
[20] S. Kobayashi, “amulog,” https://github.com/amulog/amulog.
[21] S. Kobayashi, “log2seq,” https://github.com/amulog/log2seq.

予備評価 – 方針

- 既存手法(正規表現)との処理時間の比較を行う
- オープンソースルータFrrouting[18]を対象とする
  - ソースコード: FRRouting バージョン8.5
  - ログメッセージ: DockerでFRRoutingを用いた模倣ネットワークを構築し、netroub[22,23]を用いた障害再現によりログを収集
    - ➢6,481のログ出力フォーマット、89,865行の入力ログメッセージ
- 評価環境
  - AMD Ryzen 7 7700, Ubuntu Server 22.04 (x86_64), メモリ64GB

[18] FRRouting Project, “Frrouting,” https://frrouting.org/, 2017.
[22] C. Regal-Mezin, et al. “netroub: Towards an emulation platform for network trouble scenarios,” CoNEXT-SW 2023, pp.17–18, 2023
[23] C. Regal-Mezin, “netroub,” https://github.com/3atlab/netroub.

予備評価 – 処理時間

手法	処理時間 (秒)
正規表現 (既存手法)	517.19
SCOLM (提案手法)	**5.44**
SCOLM – WSPTの 初期状態が空	5.80
SCOLM – WSPTを すべて事前生成	5.25

提案手法は既存手法に比べ
95倍の速度で処理可能

単純なWS-templateの生成を
行わない場合の性能

既に全てのWS-templateがWSPTに
追加された状態で開始
≒ WSPTのみの場合 (理想条件)

予備評価 – 処理時間の推移

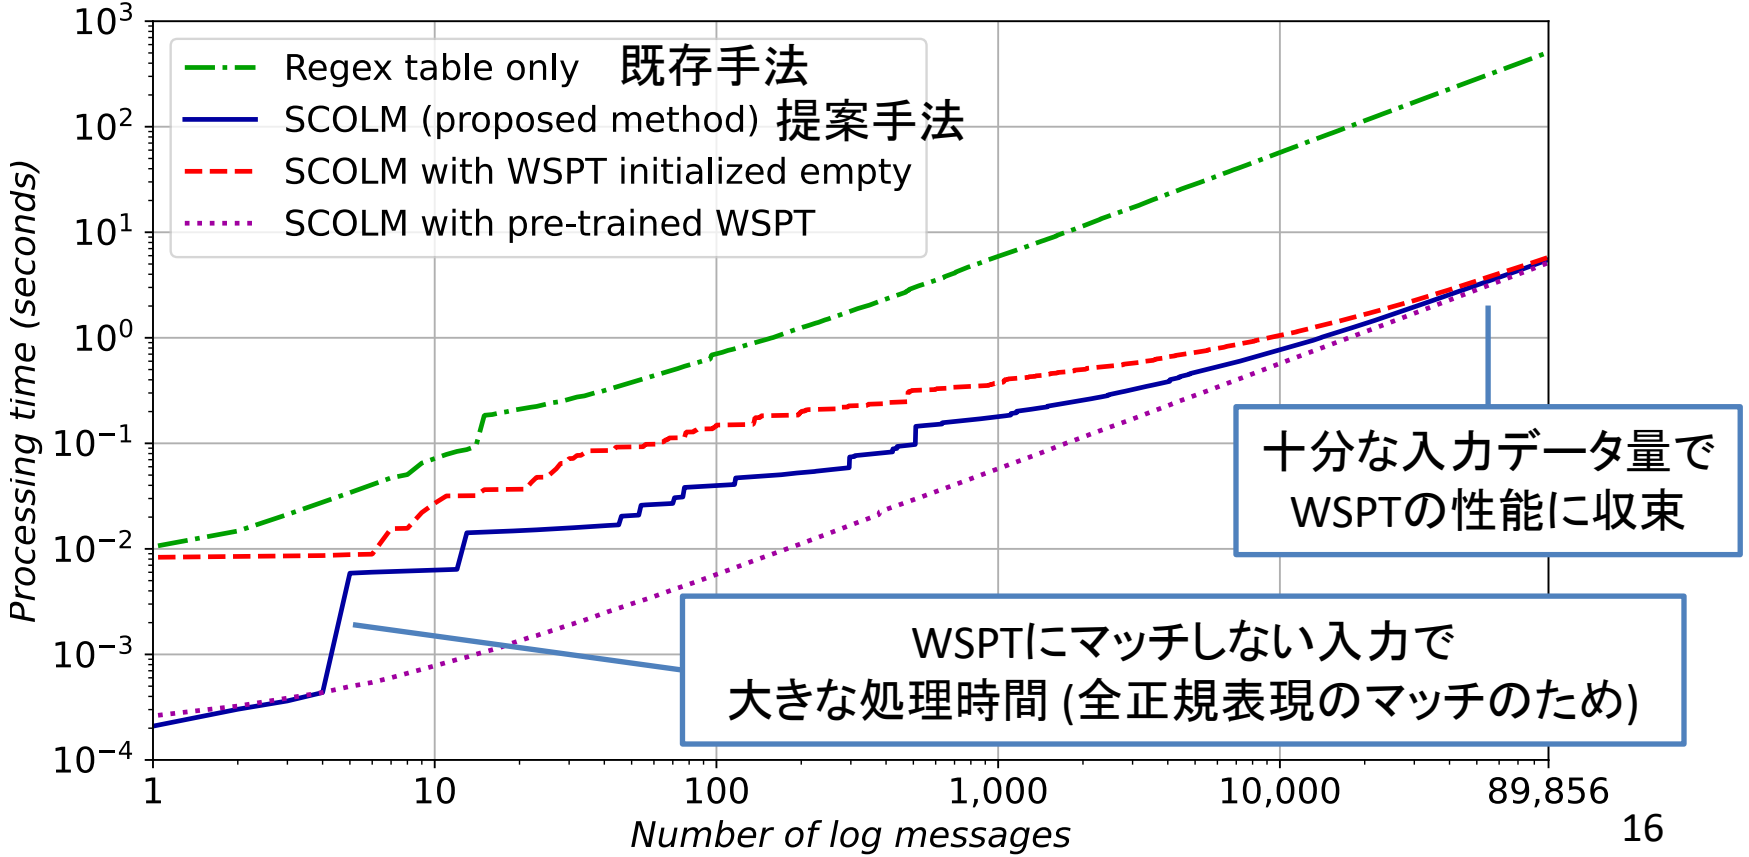

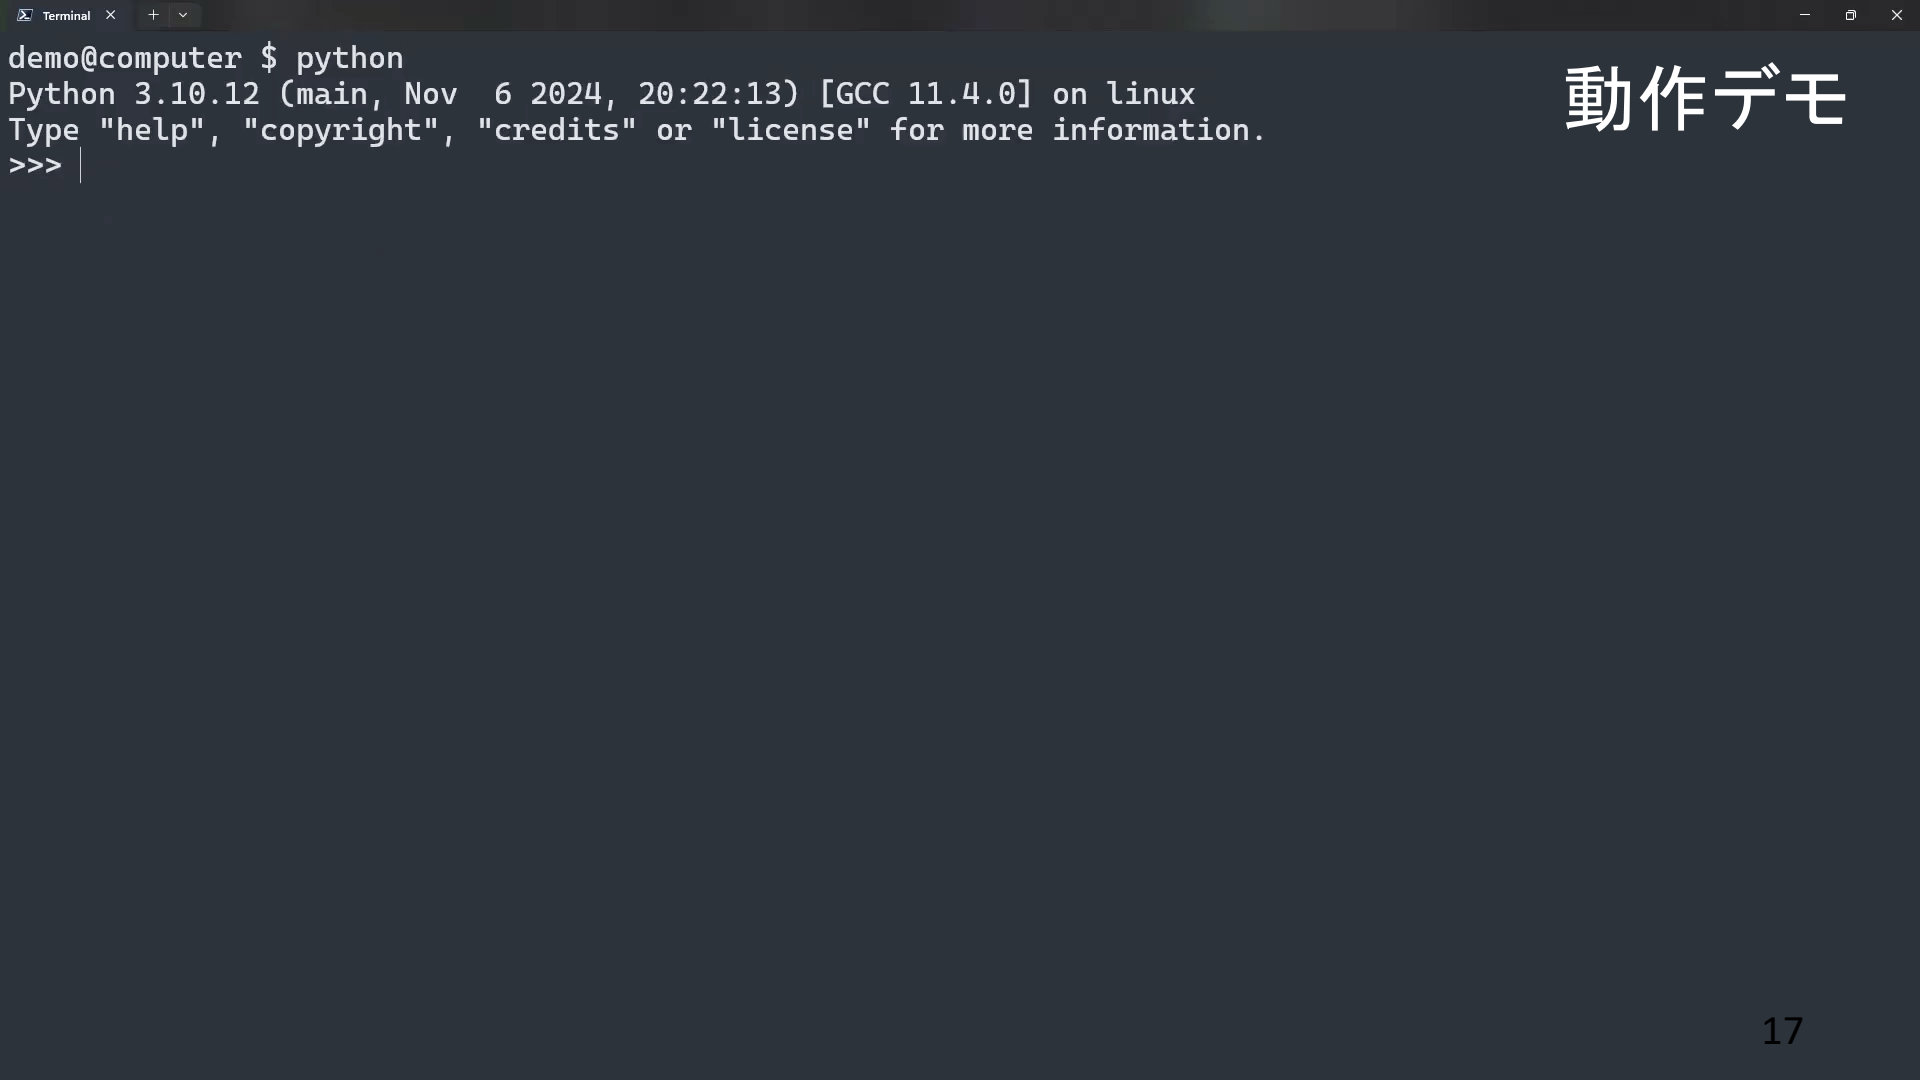
Terminal
demo@computer $ python
Python 3.10.12 (main, Nov 6 2024, 20:22:13) [GCC 11.4.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>>
動作デモ

議論

- 他ソフトウェアへの応用性
  - ソフトウェアの記述言語
    - ソースコード解析部分を拡張すれば、言語の制約はない
  - FRR同様、独自のログ出力元関数を持つ場合 (syslogのwrapper)
    - 事前に候補の関数名を与えれば有効 (例: zlog_debug, ...)
  - ログのFormattingが出力元関数外で行われている場合
    - 例: 処理過程で文字列が順次結合されてログを生成している場合
    - 既存手法/提案手法のアプローチでは適切なフォーマットが得られない
    - ソースコードの静的解析などが必要か

まとめ

- ネットワークのトラブルシューティング支援を目指し、ネットワークログの出力元関数を自動特定するシステムを設計
  - 正規表現とWSPTを組み合わせたログとソースコードの高速な照合技術を提案
- SCOLMとして実装、FRRoutingを対象に処理時間評価
  - Dockerベースの仮想ネットワークで収集したログを評価に利用
  - 既存手法と比較して95倍の速度で処理可能
- 今後の課題
  - 出力元関数特定の信頼性・精度の評価

正規表現からWS-templateへの変換

1. 入力のログメッセージを単語分割する
2. 入力のログメッセージにおいて、正規表現パターンの変数部分に対応する位置を抽出する
3. 単語分割されたログメッセージにおいて、正規表現パターンの変数部分に対応する文字列を含む単語をワイルドカードに置き換える

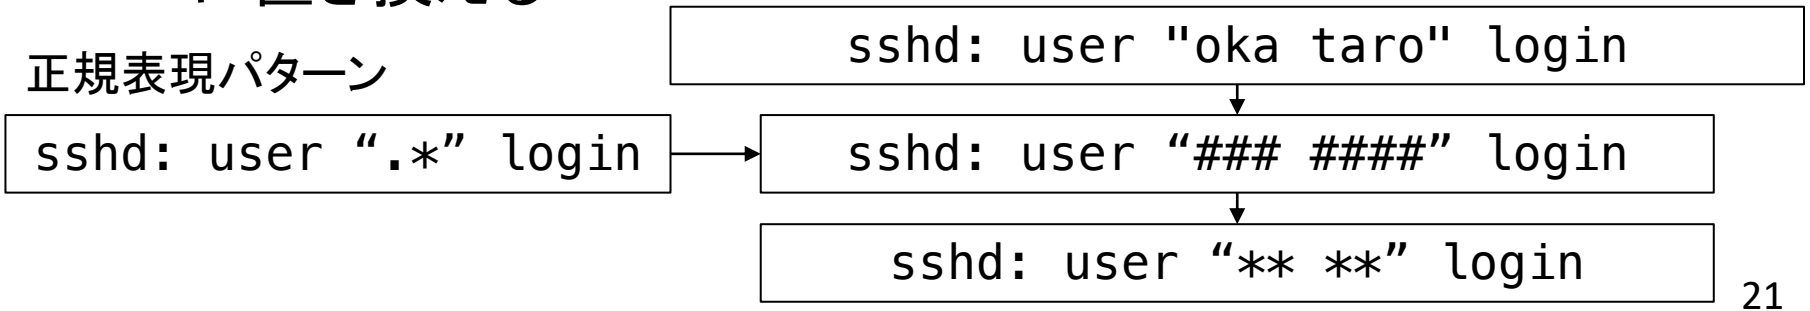

FRRのログメッセージ収集

- Containerlabを用いてDockerベースのネットワークを構築
- netroubを用いて上記ネットワーク上でさまざまな障害を再現
  - 例: 機器の停止、遅延、パケットロス、パケットの複製・破損など
  - 全部で25シナリオ
- syslogによりFRRのログを収集してデータセットとして利用

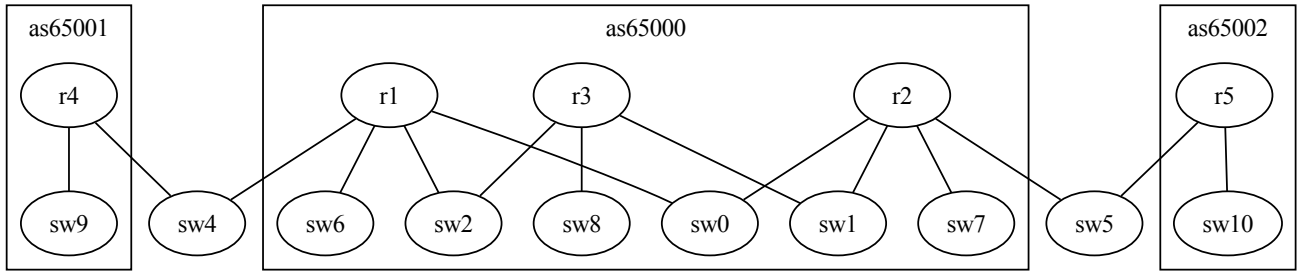

BGP+OSPFなネットワーク (frrのテスト用ネットワークbgp_featuresより)